Plan de clase — Clustering no supervisado

David Palacio · Universidad de Medellín

2026-10

Plan de clase — Clustering no supervisado

> ***Para el docente, uso privado.*** *Este documento vive en* `docs/plan-docente/`*, excluido del sitio público (*`_config.yml`*). Es la secuencia que yo (David) sigo para dictar la introducción a clustering antes de abrir el proyecto 00. Nadie más necesita verlo.*

---

0. Antes de la clase (10 min de preparación)

Checklist:

- ☐ Entorno activo: `uv sync --all-extras` en la raíz del repo.
- ☐ Terminal abierta en la raíz del repo.
- ☐ Jupyter Lab arrancado: `uv run jupyter lab`.
- ☐ Dos pestañas listas:
  1. `tutorials/13-clustering-no-supervisado/01-teoria.ipynb`
  2. `projects/00-segmentacion-clientes/notebooks/10_segmentacion_no_supervisada.ipynb`
- ☐ Proyector probado. Zoom del navegador al 125% para que se lea desde el fondo del aula.
- ☐ Pizarra o iPad para dibujar la metáfora de las pizzerías.

Mensaje inicial (1 línea): *"Hasta ahora todo lo que hemos hecho era supervisado. Hoy quitamos la respuesta correcta y vemos qué pasa."*

---

1. Durante la clase — secuencia total ~75 min

Bloque 1 · Apertura (5 min)

Preguntas abiertas al aula, **sin abrir nada todavía**:

- ¿Qué es “aprendizaje supervisado”?
- Si yo les doy datos de clientes **sin decir** quiénes son “buenos” o “malos”, ¿cómo encuentran grupos?
- ¿Han escuchado “K-Means”? ¿“clustering”?

Objetivo: activar lo que ya saben y abrir la curiosidad.

Bloque 2 · Supervisado vs no supervisado (5 min)

Abrir: `01-teoria.ipynb` → Secciones 0.

Ejecutar: la celda del scatter dual (supervisado coloreado vs todo gris).

Punto a enfatizar: *“En la vida real los datos vienen como la figura de la derecha. El algoritmo propone una estructura, nosotros decidimos si tiene sentido.”*

Pregunta al aula: *“Cuántos grupos ven en la figura de la derecha?”* — casi todos dirán 3. Perfecto, es la intuición humana que vamos a formalizar.

Bloque 3 · K-Means paso a paso (15 min)

Abrir: `01-teoria.ipynb` → Sección 1.

Antes de ejecutar la celda de las 6 iteraciones, dibujar en la pizarra la **metáfora de las pizzerías**:

1. 3 puntos aleatorios = “aquí abriré las pizzerías”
2. Cada cliente al local más cercano = asignación
3. “Me doy cuenta de que mis clientes están más al norte, muevo el local” = actualización del centroide
4. Repetir hasta estabilizar

Ejecutar: la celda de las 6 iteraciones.

Punto a enfatizar: *“Las X negras parten en cualquier lado y se asientan. Esto son 6 iteraciones; en la práctica sklearn hace esto muchas veces desde posiciones aleatorias distintas (`n_init=10`) y se queda con la mejor solución.”*

Pregunta trampa: *"¿Qué pasaría si eligiéramos los 3 puntos iniciales todos muy cerca?"* → Puede converger a un mínimo local. Por eso `n_init=10`.

Bloque 4 · Elegir k (10 min)

Abrir: `01-teoria.ipynb` → Sección 2.

Antes de ejecutar las métricas, mostrar primero el scatter de k=2, k=4, k=8.

Punto a enfatizar: *"K-Means siempre te devuelve `k` grupos. Con k=8 parte artificialmente los 3 grupos reales. Elegir `k` es nuestra responsabilidad, no del algoritmo."*

Ejecutar: las curvas de elbow + silhouette.

Punto a enfatizar: *"En este dataset tan limpio ambas métricas coinciden en k=3. En datos reales suelen discrepar — ya veremos en el cuaderno 10 que silhouette dice una cosa y davies_bouldin dice otra."*

Esto es el gancho para el proyecto 00.

Bloque 5 · DBSCAN paso a paso (15 min)

Abrir: `01-teoria.ipynb` → Sección 3.

Antes de ejecutar, dibujar en pizarra la **metáfora del mapa nocturno**:

1. Vista aérea de una ciudad en la noche
2. Zonas brillantes = barrios (clusters)
3. Luces aisladas = casas rurales (ruido)
4. DBSCAN pregunta: "¿dónde hay mucha gente cerca?"

Explicar los **dos parámetros** antes de ver código: - **ε (eps)**: radio del vecindario - **min_samples**: cuántos vecinos necesita un punto para ser núcleo

Y los **tres tipos de punto**: núcleo, frontera, ruido.

Ejecutar: el scatter de DBSCAN sobre half-moons + ruido.

Punto a enfatizar: *"Fíjense: encontró las dos medias lunas sin problema. K-Means no podría — asumiría nubes esféricas. Y los 10 puntos aleatorios quedaron marcados como ruido (-1), no se forzaron a entrar en algún cluster."*

Pregunta trampa: *"¿Qué pasa si bajo ε a 0.05?"* → Casi todo se vuelve ruido. *"¿Y si lo subo a 1.0?"* → Las dos medias lunas se fusionan en un solo cluster.

Bloque 6 · Comparación (10 min) — el bloque más importante

Abrir: `01-teoria.ipynb` → Sección 4.

Ejecutar: la grilla 2×3 (K-Means vs DBSCAN sobre blobs, moons, ruido).

Puntos a enfatizar, en orden:

1. **Blobs**: ambos funcionan. Preferir K-Means por rapidez.
2. **Half-moons**: K-Means parte las medias lunas por la mitad; DBSCAN las encuentra enteras. *"La forma de los datos importa."*
3. **Blobs con ruido**: K-Means fuerza el ruido en algún cluster (contamina los centroides). DBSCAN marca ruido como -1. *"Si tus datos tienen outliers que no quieres mezclar, DBSCAN primero."*

Cerrar con la tabla de "cuándo usar cada uno" del notebook.

Bloque 7 · Puente al proyecto 00 (5 min)

Abrir: `01-teoria.ipynb` → Sección 5.

Leer en voz alta los 4 bullets de "Lo que ya sabes antes de abrirlo". Son **predicciones de lo que verán** en el cuaderno 10. Si los estudiantes lo leen antes, no se van a sorprender cuando:

- Las métricas discrepen (silhouette = 2, davies_bouldin = 4).
- Elijamos k = 4 por razones de negocio aunque silhouette diga 2.
- DBSCAN marque ~46% de ruido.

Dejar las 3 preguntas de reflexión del cuaderno teórico abiertas. Yo quiero oír al menos 2 respuestas antes de pasar al proyecto.

Bloque 8 · Abrir el proyecto 00 (10 min + lo que falte)

Cerrar `01-teoria.ipynb`. **Abrir:** `projects/00-segmentacion-clientes/notebooks/10_segmentacion_no_supervisada.ipynb`

Las secciones del cuaderno 10 **espejan** las del cuaderno teórico:

Cuaderno 10 (sección)	Corresponde a (teoría)
1. k-means con silhouette	Sección 2 (elegir k)
2. DBSCAN como contraste	Sección 3 + 4 (DBSCAN + comparación)
3. Perfilar y nombrar segmentos	Nuevo — RFM específico
4. Fichas de acción	Nuevo — puente a marketing

No ejecutar en vivo si el tiempo apremia — ya está ejecutado y guardado. Hacer scroll y comentar los resultados.

---

2. Preguntas típicas de estudiantes (con respuesta corta)

P: ¿Por qué K-Means no funciona con los half-moons? R: Porque minimiza distancia al centroide; una media luna no tiene un "centro" que la represente — el centro cae **fuera** de la luna. Falla estructural.

P: ¿Cómo elijo ε en DBSCAN sin probar? R: Hay una heurística: calcular la distancia al `k`-ésimo vecino de cada punto (`k = min_samples`), ordenar y buscar el "codo". Pero en la práctica, probar varios ε es más honesto.

P: ¿Puedo usar K-Means y DBSCAN juntos? R: Sí. Patrón común: DBSCAN primero para marcar outliers → quitarlos → K-Means para segmentar el resto. En el proyecto 00 lo mencionamos pero no lo implementamos.

P: ¿Qué pasa si mis variables tienen escalas distintas (precio en dólares, edad en años)? R: K-Means y DBSCAN usan distancia euclidiana. **Siempre escalar antes.** El cuaderno 10 usa `StandardScaler` dentro del preprocesador.

P: ¿Cuántos clusters hay "realmente"? R: No hay una respuesta correcta. Hay k que son más útiles para un objetivo (ej. 4 segmentos de marketing es manejable, 15 no). La métrica propone, el negocio decide.

---

3. Puntos a NO olvidar enfatizar

1. **No supervisado no significa "sin trabajo humano".** Hay que decidir k, interpretar segmentos, ponerles nombres. Es más subjetivo que supervisado.

2. **Las métricas discrepan en datos reales.** Mostrar explícitamente que en el cuaderno 10 silhouette elige 2 y davies_bouldin elige 4.
3. **DBSCAN no es "mejor" ni "peor" que K-Means.** Son herramientas para problemas distintos. La forma de los datos manda.
4. **Siempre escalar antes de clustering.** Si una variable va de 0 a 1 y otra de 0 a 1 000 000, la segunda domina la distancia.
5. **El ruido en DBSCAN no es un bug.** En el cuaderno 10, ~46% de los clientes quedan como ruido → eso dice "DBSCAN no segmenta bien acá", no "DBSCAN está roto".

---

4. Si tengo poco tiempo (versión 45 min)

Prioridades (en orden):

1. Bloque 1 + 2: supervisado vs no supervisado (10 min)
2. Bloque 3: K-Means paso a paso (15 min)
3. Bloque 6: comparación con DBSCAN (10 min) — **saltar el detalle de los parámetros de DBSCAN**; solo decir "existe y detecta formas no esféricas"
4. Bloque 8: abrir el cuaderno 10, correr y comentar (10 min)

Dejar las secciones 2 (elegir k) y 5 (puente) como lectura previa a la siguiente clase. Y asignar las 3 preguntas de reflexión del cuaderno teórico como entregable rápido.

---

5. Material de respaldo

- `projects/00-segmentacion-clientes/HALLAZGOS.md` — contexto RFM que los estudiantes **ya deberían haber leído** antes de llegar al cuaderno 10.
- Métricas en `src/segmentacion/models/clustering.py`: `find_optimal_k`, `fit_kmeans`, `fit_dbscan`, `evaluate_clustering`. Si alguien quiere ver el código de las métricas, aquí está.
- `tests/models/` — ejemplos de qué está probado. Útil para preguntas tipo "¿cómo saben que esto no está roto?".

---

6. Al terminar

- [ ] Las 3 preguntas de reflexión del cuaderno teórico, al menos 2 respondidas en voz alta.
- [ ] Alguien del aula capaz de decir en voz alta: *“K-Means asume formas esféricas, DBSCAN no.”*
- [ ] Nadie confundido por por qué silhouette dice 2 pero elegimos 4.
- [ ] Pasada clara al próximo tema (modelos supervisados ya cubiertos en 06-09, apps/Streamlit en U4).